

Основы построения файловых систем




Что мы хотим от ФС:

- сохранять данные

Что мы хотим от ФС:

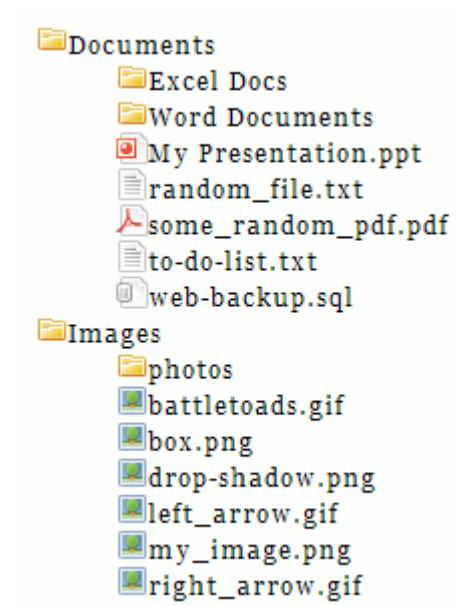
- сохранять данные



Если файлов тысячи, то
список становится неудобным

Что мы хотим от ФС:

- сохранять данные,
- упорядочивать их



Что мы хотим от ФС:

- сохранять данные,
- упорядочивать их,
- предоставлять к ним доступ

Сегодня мы будем говорить только о локальных ФС, т.е. тех, которые хранят данные на том компьютере, где исполняется ОС.

Какой интерфейс хочется иметь:

```
f = open("./pstorage-fes/src/fes.c");  
read(f, buffer, size);  
.....  
write(f, buffer, size);  
.....  
close(f);
```

Какой интерфейс хочется иметь:

```
f = open("./pstorage-fes/src/fes.c");  
read(f, buffer, size);  
.....  
write(f, buffer, size);  
.....  
close(f);
```

Какой интерфейс есть у жёсткого диска:

- * прочесть сектор* номер N,
- * записать сектор номер M.

** сектор – блок длиной 512 или 4096 байт*


Какой интерфейс хочется иметь:	Какой интерфейс есть у жёсткого диска:
<pre>f = open("./pstorage-fes/src/fes.c"); read(f, buffer, size); write(f, buffer, size); close(f);</pre>	<ul style="list-style-type: none">* прочесть сектор* номер N,* записать сектор номер M. <p><i>* сектор – блок длиной 512 или 4096 байт</i></p>

Задача ФС:	
Используя только интерфейс жёсткого диска, предоставить пользователю возможность	
<ul style="list-style-type: none">• создавать каталоги и файлы,• отыскивать каталоги и файлы по имени,• писать данные в файлы и читать их,• делать вышеперечисленное надёжно и эффективно.	

Пример задачи, которая возникает у авторов ФС: как организовать список файлов*?

Линейный список, где файлы идут в порядке создания Дерево поиска

file15, file1,
file2, file3,
file4, file9,
file6, file8,
file7, file5,
file12, file11,
file10, file13,
file14, file0




** для простоты пусть каждый прямоугольник на рисунке будет непрерывным блоком на диске*

Пример задачи, которая возникает у авторов ФС: как организовать список файлов*?

Линейный список, где файлы идут в порядке создания Дерево поиска

file15, file1,
file2, file3,
file4, file9,
file6, file8,
file7, file5,
file12, file11,
file10, file13,
file14, file0



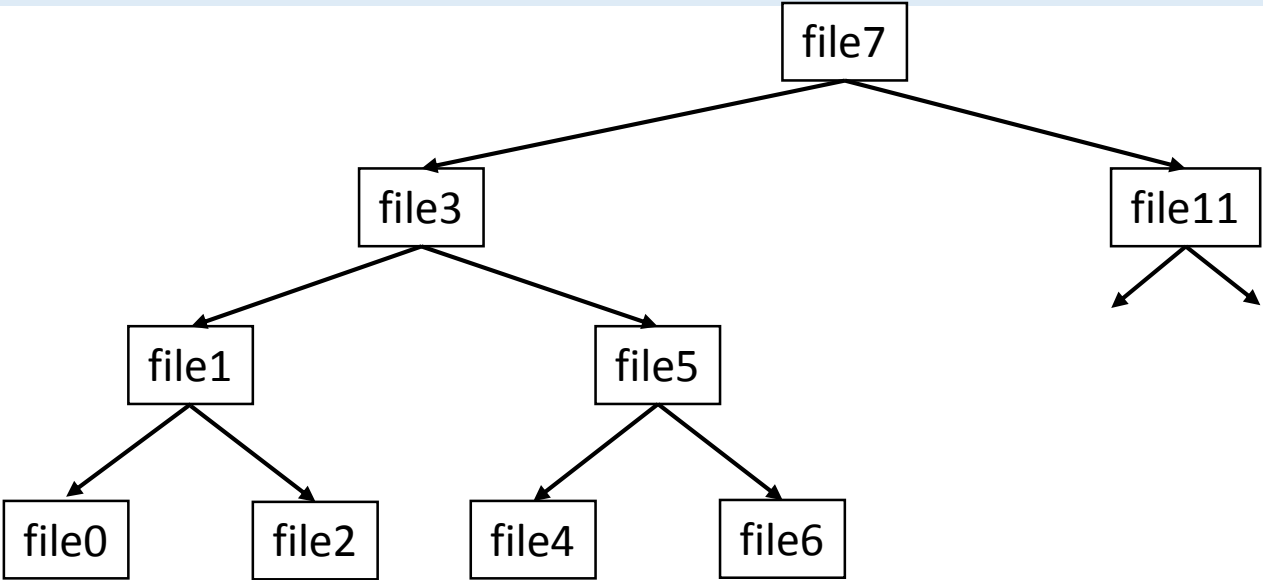
Чтобы найти элемент, надо 16 сравнений Чтобы найти элемент, надо 4 сравнения. Win?

** для простоты пусть каждый прямоугольник на рисунке будет непрерывным блоком на диске*


Пример задачи, которая возникает у авторов ФС: как организовать список файлов*?

Линейный список, где файлы идут в порядке создания Дерево поиска

file15, file1,
file2, file3,
file4, file9,
file6, file8,
file7, file5,
file12, file11,
file10, file13,
file14, file0



Чтобы найти элемент, надо 16 сравнений Чтобы найти элемент, надо 4 сравнения.




** для простоты пусть каждый прямоугольник на рисунке будет непрерывным блоком на диске*

Читающая головка диска движается медленно, случайные чтения у диска получаются плохо.

Для сравнения:


- Скорость линейного чтения ≈ 100 MB/sec, т.е. ≈ 10 msec на 1 MB,
- Время позиционирования головки ≈ 10 msec.



Пример задачи, которая возникает у авторов ФС: как организовать список файлов*?

Линейный список, где файлы идут в порядке создания Дерево поиска


file15, file1,
file2, file3,
file4, file9,
file6, file8,
file7, file5,
file12, file11,
file10, file13,
file14, file0



Переход на начало списка:	≈10msec	Тут нужны 4 позиционирования читающей головки, т.е. меньше, чем в 40msec мы не уложимся.
Чтение списка:	≈1msec (≈1MB)	
Поиск (список уместился в RAM):	<1msec	

** для простоты пусть каждый прямоугольник на рисунке будет непрерывным блоком на диске*

Та же проблема с содержимым файлов: их надо располагать так, чтобы не создавать случайного доступа к диску.



Устройства хранения данных:

HDD (Hard Disk Drive, a.k.a Rotating drive,
a.k.a Spinning rust)

+ достаточно быстрое линейное чтение (≈ 100 MB/sec)
- очень медленный случайный доступ (≈ 100 IOPS)

** IOPS – Input/output Operations Per Second*

** Данные для Intel SSD DC S3700*

Устройства хранения данных:

HDD (Hard Disk Drive, a.k.a Rotating drive, a.k.a Spinning rust)	<ul style="list-style-type: none">+ достаточно быстрое линейное чтение (≈ 100 MB/sec),- очень медленный случайный доступ (≈ 100 IOPS).
Flash memory	<ul style="list-style-type: none">+ быстрое линейное чтение,+ нет времени «позиционирования головок»,- перезаписывать можно только “rewrite block” целиком, а он несколько MB в размере,- небольшое число циклов перезаписи.

* IOPS – Input/output Operations Per Second
* Данные для Intel SSD DC S3700

Устройства хранения данных:

HDD (Hard Disk Drive, a.k.a Rotating drive, a.k.a Spinning rust)	<ul style="list-style-type: none">+ достаточно быстрое линейное чтение (≈ 100 MB/sec),- очень медленный случайный доступ (≈ 100 IOPS).
Flash memory	<ul style="list-style-type: none">+ быстрое линейное чтение,+ нет времени «позиционирования головок»,- перезаписывать можно только “rewrite block” целиком, а он несколько MB в размере,- небольшое число циклов перезаписи.
SSD (Solid State Drive)	<p>Flash + компьютер, который прячет сложность работы с “rewrite blocks”.</p> <ul style="list-style-type: none">+ быстрый линейный доступ (≈ 500 MB/sec sequential read*),+ быстрый произвольный доступ (≈ 75.000 IOPS),- деградация производительности со временем,- желательна специальной поддержки со стороны ОС, например, ATA TRIM.

* IOPS – Input/output Operations Per Second
* Данные для Intel SSD DC S3700

Устройства хранения данных:

HDD (Hard Disk Drive, a.k.a Rotating drive, a.k.a Spinning rust)	<ul style="list-style-type: none">+ достаточно быстрое линейное чтение (≈ 100 MB/sec),- очень медленный случайный доступ (≈ 100 IOPS).
Flash memory	<ul style="list-style-type: none">+ быстрое линейное чтение,+ нет времени «позиционирования головок»,- перезаписывать можно только “rewrite block” целиком, а он несколько MB в размере,- небольшое число циклов перезаписи.
SSD (Solid State Drive)	<p>Flash + компьютер, который прячет сложность работы с “rewrite blocks”.</p> <ul style="list-style-type: none">+ быстрый линейный доступ (≈ 500 MB/sec sequential read*),+ быстрый произвольный доступ (≈ 75.000 IOPS),- деградация производительности со временем,- желательна специальной поддержки со стороны ОС, например, ATA TRIM.
NVM (Non-Volatile Memory)	<p>Память с произвольным доступом, которая не стирается при выключении питания.</p> <ul style="list-style-type: none">+ по скорости сопоставима с DRAM,+ объём – единицы терабайт,- пока разработчики не понимают, как поддержать NVM со стороны ОС.

* IOPS – Input/output Operations Per Second
* Данные для Intel SSD DC S3700

API для чтения/записи файлов:

Надо скрыть от пользователя особенности оборудования и предоставить единообразный способ доступа к данным на разных устройствах.

- POSIX (Portable Operating System Interface),
- Windows,
- memory-mapped files.

POSIX Filesystem API

Структура ФС – древовидная с одним корнем:

```
/
├── bin
├── boot
├── dev
├── etc
├── home
│   └── artem
├── lib
├── lib32
├── lib64
├── libx32
├── lost+found
├── media
├── mnt
├── opt
└── proc
```

POSIX Filesystem API

Структура ФС – древовидная с одним корнем:

```
/
├── bin
├── boot
├── dev
├── etc
├── home
│   └── artem
├── lib
├── lib32
├── lib64
├── libx32
├── lost+found
├── media
├── mnt
├── opt
└── proc
```

Windows Filesystem API


ФС представляет собой лес, корнями которого являются диски:

Drive		
C: fixed	931,17 G	775,76 G
D: fixed	0,91 T	482,52 G
X: network		
Y: network		
Z: network		

..	archive_io.h
dedup	archive_io_astor.h
Makefile	archive_io_local.h
TODO	archive_item.h
archive_api.c	archive_item_cache.h
archive_api_remote.c	archive_locking.h

POSIX Filesystem API

Структура ФС – древовидная с одним корнем:



Filesystem Hierarchy Standard:

Linux:

http://refspecs.linuxfoundation.org/FHS_2.3/fhs-2.3.pdf

FreeBSD:

<https://www.freebsd.org/doc/handbook/dirstructure.html>

Windows Filesystem API


ФС представляет собой лес, корнями которого являются диски:

Drive		
C: fixed	931,17 G	775,76 G
D: fixed	0,91 T	482,52 G
X: network		
Y: network		
Z: network		

..	archive_io.h
dedup	archive_io_astor.h
Makefile	archive_io_local.h
TODO	archive_item.h
archive_api.c	archive_item_cache.h
archive_api_remote.c	archive_locking.h

POSIX Filesystem API

Структура ФС – древовидная с одним корнем:



Filesystem Hierarchy Standard:

Linux:

http://refspecs.linuxfoundation.org/FHS_2.3/fhs-2.3.pdf

FreeBSD:

<https://www.freebsd.org/doc/handbook/dirstructure.html>

Windows Filesystem API

ФС представляет собой лес, корнями которого являются диски:

Drive		
C: fixed	931,17 G	775,76 G
D: fixed	0,91 T	482,52 G
X: network		
Y: network		
Z: network		

..	archive_io.h
dedup	archive_io_astor.h
Makefile	archive_io_local.h
TODO	archive_item.h
archive_api.c	archive_item_cache.h
archive_api_remote.c	archive_locking.h

\Global??\C:\foo\bar.txt

Проблема с терминологией

ФС – видимая пользователю иерархия каталогов и файлов

ФС – механизм расположения файлов на диске

```
/
├── bin
├── boot
├── dev
├── etc
├── home
│   └── artem
├── lib
├── lib32
├── lib64
├── libx32
├── lost+found
├── media
├── mnt
├── opt
└── proc
```

Drive		
C: fixed	931,17 G	775,76 G
D: fixed	0,91 T	482,52 G
X: network		
Y: network		
Z: network		

