Основы построения файловых систем

Виртуальные FS в Linux: procfs

В Linux есть файловая система, каталоги в корне которой соответствуют исполняющимся процессам, а файлы внутри каждого каталога описывают состояние процесса.

```
artem@dev:~$ ls -lh /proc/self/
total 0

-r--r--r-- 1 artem artem 0 Oct  2 10:08 cmdline
lrwxrwxrwx 1 artem artem 0 Oct  2 10:08 cwd -> /home/artem
lrwxrwxrwx 1 artem artem 0 Oct  2 10:08 exe -> /bin/ls
dr-x------ 2 artem artem 0 Oct  2 10:08 fd
-r--r--r-- 1 artem artem 0 Oct  2 10:08 maps
-r--r--r-- 1 artem artem 0 Oct  2 10:08 stat
......
```

Домашнее задание:

- man 5 proc,
- что находится в файле /proc/PID/auxv и как выглядит стек процесса сразу после execve()?
- напишите программу, которая спрячет первый аргумент командной строки из /proc/PID/cmdline (подсказка: man prctl + операция PR_SET_MM),
- напишите аналоги
  - ps
  - lsof

Виртуальные FS в Linux: FUSE

FUSE (Filesystem in USer spacE) – это способ создания драйверов файловых систем, которые исполняются как пользовательские процессы, а не часть ядра.

Драйверы FUSE работают как сервера, которые обслуживают один pipe. Они читают оттуда команды вроде “найти элемент каталога по имени”, “открыть/закрыть файл”, “прочесть/записать данные в файл”. Клиентом такого сервера является ядро ОС.

Пример: sshfs.

Преимущества FUSE:

- Позволяет легко экспериментировать,
- Реализации ФС могут иметь сложные зависимости, которые были бы нежелательны в ядре,
- Может использоваться непривилегированными пользователями.

Недостатки FUSE:

- Низкая производительность.

Домашнее задание:

- прочтите документацию по FUSE high level API,
- напишите драйвер для FUSE, который предоставляет ФС, состоящую из одного файла “hello”, из которого можно прочесть строку “hello, world!”; в каталоге, куда монтируется эта ФС, должны работать команды `ls` и `cat hello`.

Memory-mapped files

```
int fd = open(“file.txt”, O_RDONLY);
char *str = mmap(NULL, length, PROT_READ, MAP_PRIVATE, fd, 0);

/* work with @str as if it were an array */
printf(“%s\n”, str);

munmap(str, length);
```

Как это работает?

Виртуальная память: зачем это надо?

Процессы не имеют доступа к физической памяти.

Вместо этого, ОС предоставляют процессам линейное адресное пространство,
которое может произвольно отображаться на физическую память.

Задачи, которые решает введение виртуального адресного пространства:

1. Возможность предоставить каждому процессу единообразное адресное пространство:
   процесс просто считает, что ему доступны все адреса в диапазоне [0, MAX_ADDR),
2. Изоляция процессов,
3. Возможность прозрачно разделять часть памяти между процессами (shared libraries, text segments, etc.),
4. Возможность «незаметно» для процесса заполнять/выгружать его части из памяти:
   memory-mapped files, swapping,

Виртуальная память с точки зрения CPU

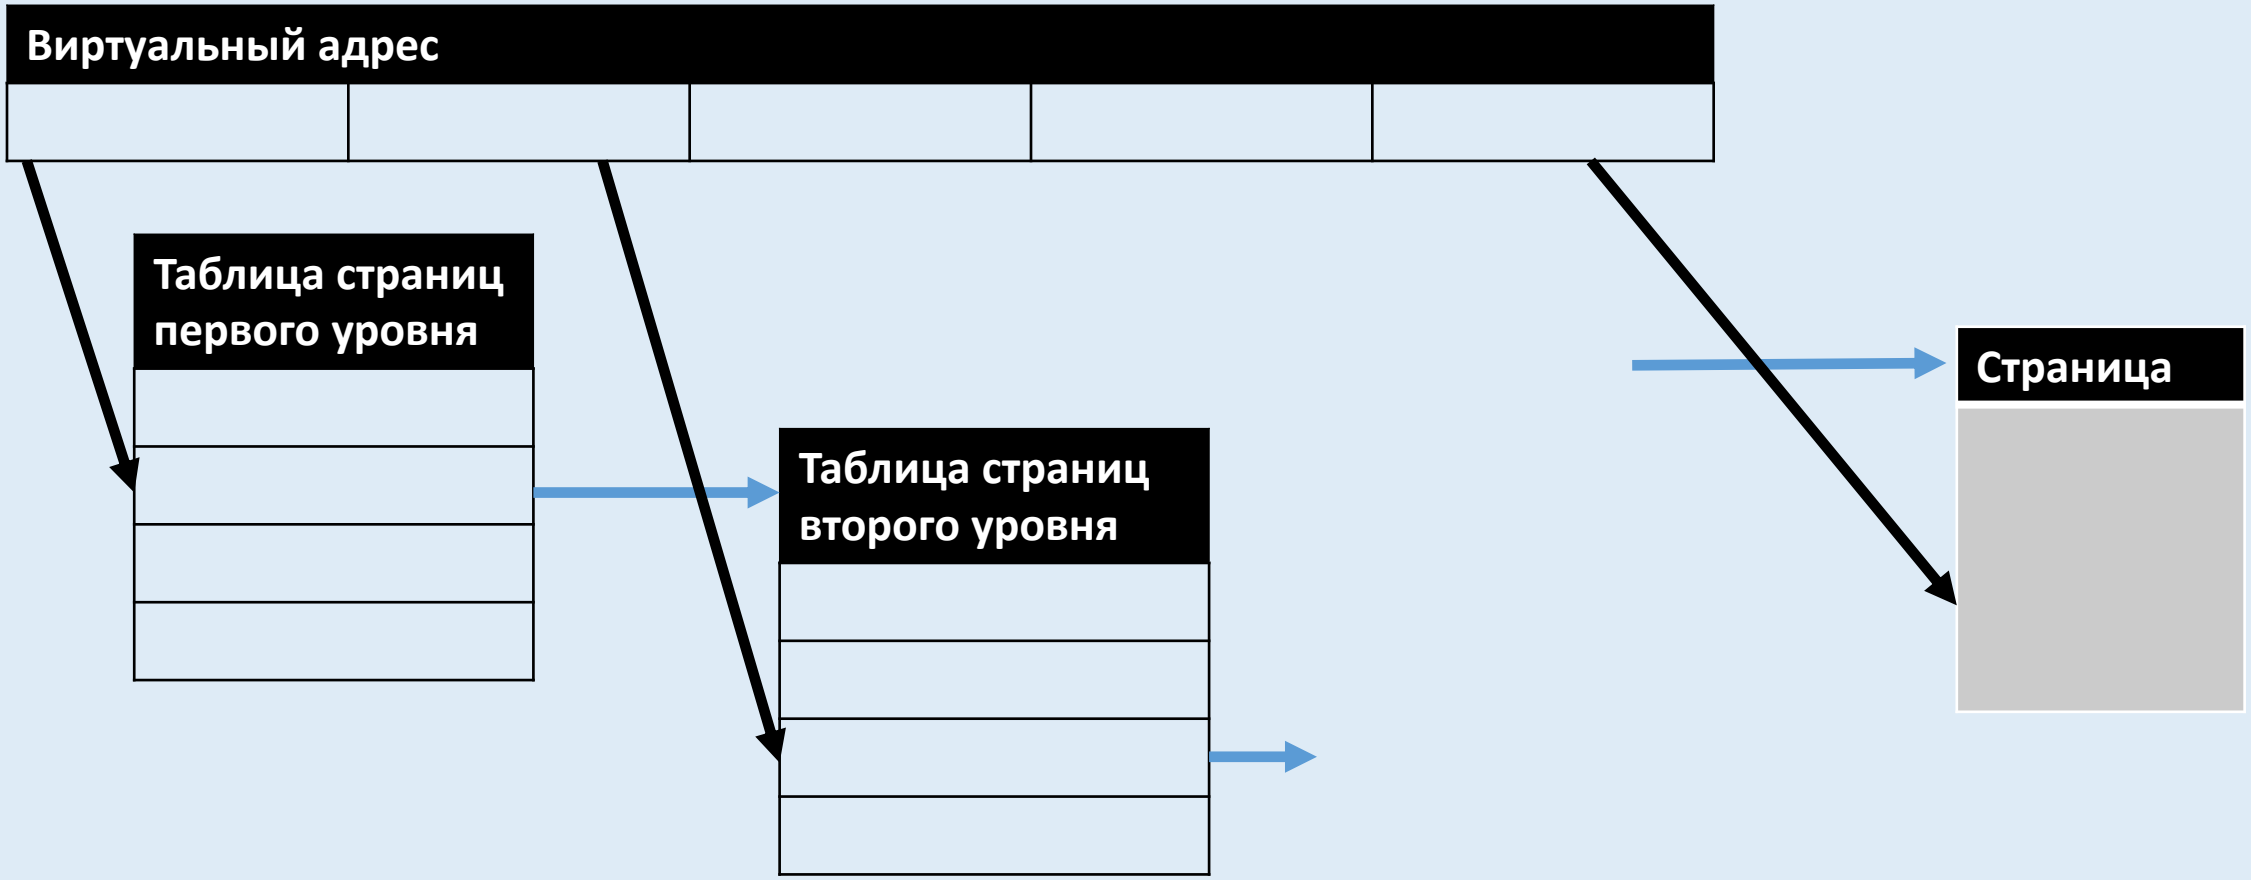

- Таблицы разрешается заполнять частично, чтобы не тратить много памяти.
- Поиск по таблицам требует много обращений к памяти, поэтому результаты преобразований адресов кешируются в TLB (Translation Look-aside Buffer)

Виртуальная память с точки зрения ОС

Для операционной системы память процесса представляется как набор VMA (Virtual Memory Area).

Каждая VMA указывает

- диапазон адресов,
- права доступа (и флаги вроде copy-on-write),
- правило, как подгружать страницы из данной VMA.

Memory-mapped files: проблемы

Если файл виден как массив в памяти, то чтение и запись делаются очень просто.

Но как

1. увеличивать размер файла?
2. обрабатывать ошибки чтения из файла?
3. обрабатывать ошибки записи в файл?

Memory-mapped files: проблемы

Если файл виден как массив в памяти, то чтение и запись делаются очень просто.

Но как

1. увеличивать размер файла?
2. обрабатывать ошибки чтения из файла?
3. обрабатывать ошибки записи в файл?

Ответ: никак.

До недавнего времени ошибки при отложенной записи (writeback) можно было легко потерять:

- https://lwn.net/Articles/718734/
- http://stackoverflow.com/q/42434872/398670

Page cache и отложенная запись (writeback)

Аналогичные проблемы с записью есть и в POSIX API:

```
int fd = open(“file.txt”, O_RDWR);
pwrite(fd, buf, size, 0);
fsync(fd);
close(fd);
```

Вызов pwrite() не записывает данные в файл, а только помещает их в page cache.
Данные будут записаны на диск только после вызова fsync() или когда ОС решит сбросить page cache на диск.

- ошибки записи будут возвращены из fsync()
- close() тоже может завершаться с ошибкой.

Page cache и отложенная запись (writeback)

fsync() и fdatasync()

- могут сказать, что записать данные не удалось,
- не указывают диапазон страниц, которые не удалось записать.

Как с этим бороться?

Page cache и отложенная запись (writeback)

fsync() и fdatasync()

- могут сказать, что записать данные не удалось,
- не указывают диапазон страниц, которые не удалось записать.

Как с этим бороться?

Упорядочивать записи в файл:

1. записать новые данные,
2. fsync(),
3. записать заголовок, который ссылается на новые данные,
4. fsync().

Page cache и отложенная запись (writeback)

fsync() и fdatasync()

- могут сказать, что записать данные не удалось,
- не указывают диапазон страниц, которые не удалось записать.

Как с этим бороться?

Упорядочивать записи в файл:

1. записать новые данные,
2. fsync(),
3. записать заголовок, который ссылается на новые данные,
4. fsync().

Как быть с перезаписями?

1. append-only files (только append и punch holes),
2. следить за использованием областей и перезаписывать только те, которые не используются.

Master-slave репликация для append-only файлов

Пусть у нас есть файловый сервер, которые предоставляет следующие операции:

- прочесть данные из файла,
- дописать данные в конец файла,
- превратить часть файла в дырку.

Как для такого файлового сервера добавить возможность асинхронной репликации? Файл на реплике всегда должен быть в согласованном состоянии.

Master-slave репликация для append-only файлов

Пусть у нас есть файловый сервер, которые предоставляет следующие операции:

- прочесть данные из файла,
- дописать данные в конец файла,
- превратить часть файла в дырку.

Как для такого файлового сервера добавить возможность асинхронной репликации? Файл на реплике всегда должен быть в согласованном состоянии.

В чём проблема:

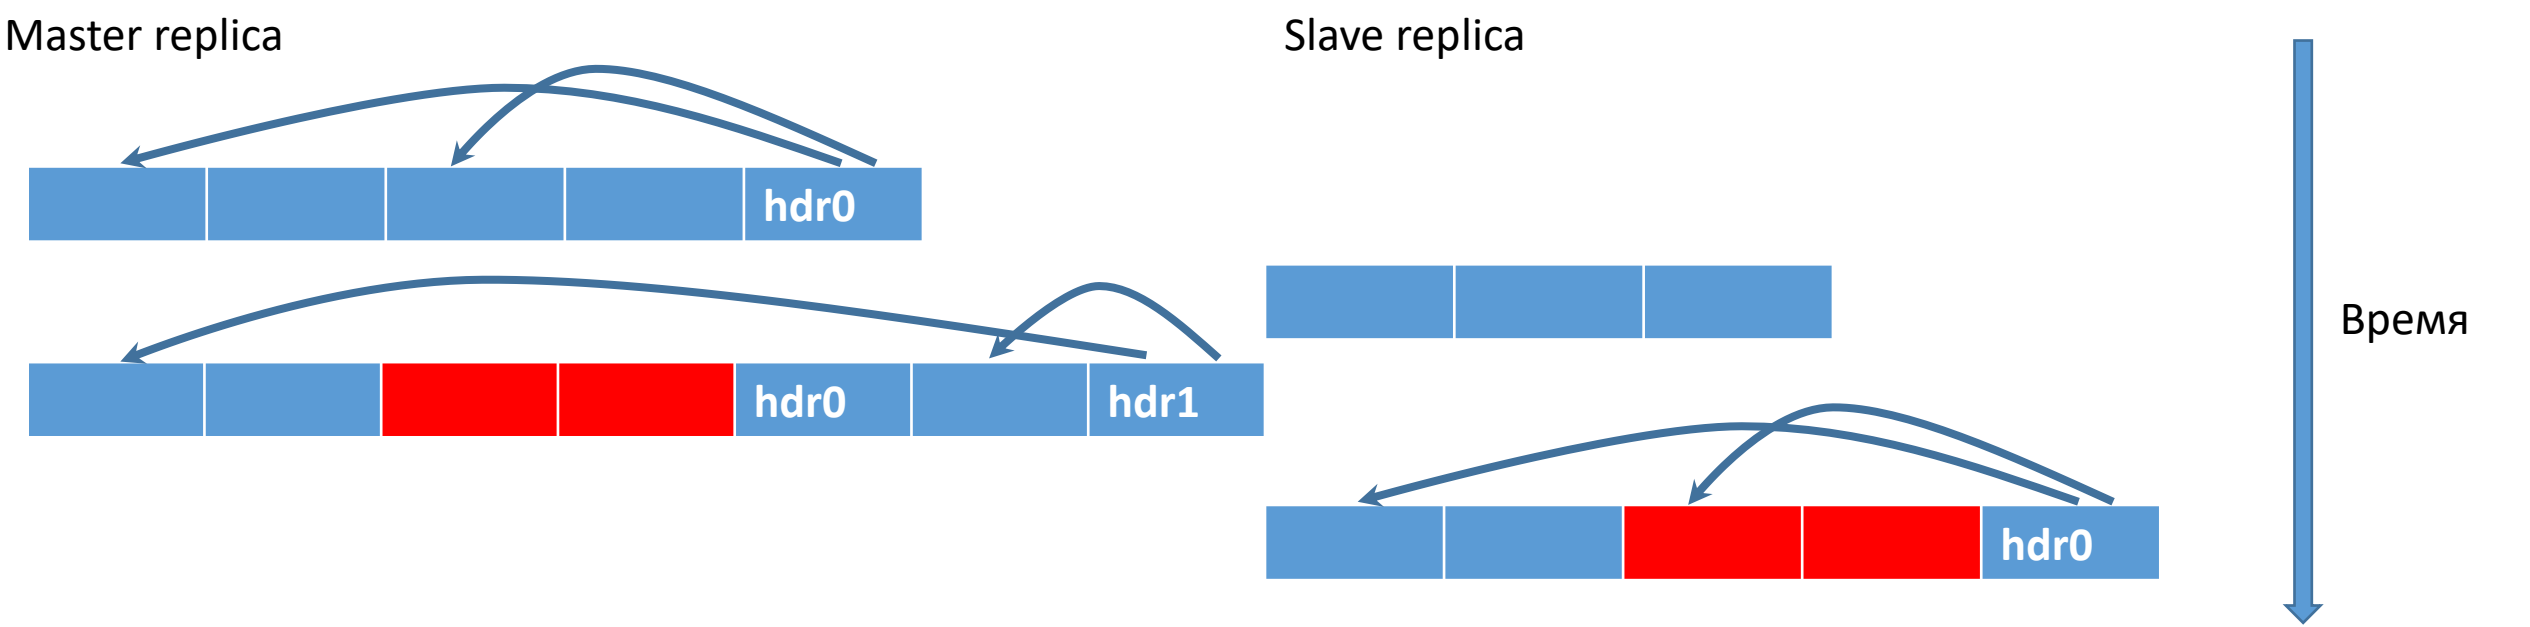

Master-slave репликация для append-only файлов

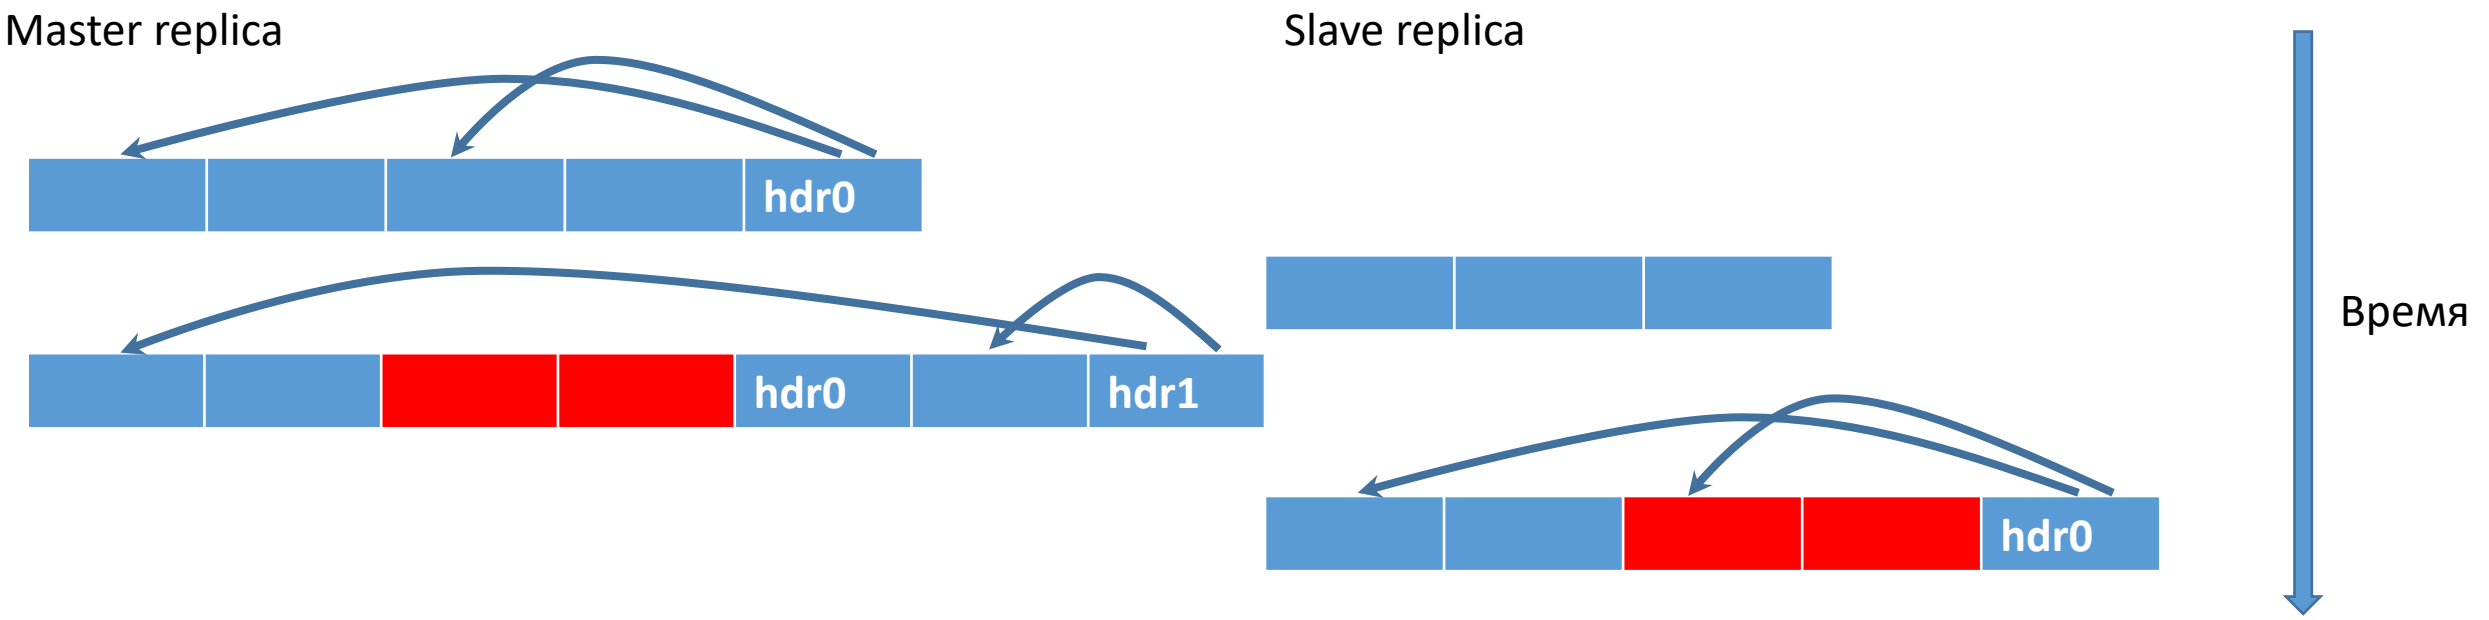

Вывод: исполнять punch_holes сразу при получении запроса нельзя, их надо журналировать и исполнять позже.

Домашнее задание: придумайте механизм журналирования дырок для master-slave репликации append-only файлов.

POSIX API	Windows API
open(const char *path, int mode, int flags)	HANDLE WINAPI CreateFile(_In_ LPCTSTR lpFileName, _In_ DWORD dwDesiredAccess, _In_ DWORD dwShareMode, _In_opt_ LPSECURITY_ATTRIBUTES lpSecurityAttributes, _In_ DWORD dwCreationDisposition, _In_ DWORD dwFlagsAndAttributes, _In_opt_ HANDLE hTemplateFile);
read(int fd, void *buf, size_t count)	BOOL WINAPI ReadFile(_In_ HANDLE hFile, _Out_ LPVOID lpBuffer, _In_ DWORD nNumberOfBytesToRead, _Out_opt_ LPDWORD lpNumberOfBytesRead, _Inout_opt_ LPOVERLAPPED lpOverlapped);
write(int fd, const void *buf, size_t count)	BOOL WINAPI WriteFile(_In_ HANDLE hFile, _In_ LPCVOID lpBuffer, _In_ DWORD nNumberOfBytesToWrite, _Out_opt_ LPDWORD lpNumberOfBytesWritten, _Inout_opt_ LPOVERLAPPED lpOverlapped);
close(int fd)	BOOL WINAPI CloseHandle(_In_ HANDLE hObject);

POSIX API	Windows API
open(const char *path, int mode, int flags)	HANDLE WINAPI CreateFile(_In_ LPCTSTR lpFileName, _In_ DWORD dwDesiredAccess, _In_ DWORD dwShareMode, _In_opt_ LPSECURITY_ATTRIBUTES lpSecurityAttributes, _In_ DWORD dwCreationDisposition, _In_ DWORD dwFlagsAndAttributes, _In_opt_ HANDLE hTemplateFile);
read(int fd, void *buf, size_t count)	BOOL WINAPI ReadFile(_In_ HANDLE hFile, _Out_ LPVOID lpBuffer, _In_ DWORD nNumberOfBytesToRead, _Out_opt_ LPDWORD lpNumberOfBytesRead, _Inout_opt_ LPOVERLAPPED lpOverlapped);
write(int fd, const void *buf, size_t count)	BOOL WINAPI WriteFile(_In_ HANDLE hFile, _In_ LPCVOID lpBuffer, _In_ DWORD nNumberOfBytesToWrite, _Out_opt_ LPDWORD lpNumberOfBytesWritten, _Inout_opt_ LPOVERLAPPED lpOverlapped);
close(int fd)	BOOL WINAPI CloseHandle(_In_ HANDLE hObject);

Синхронный и асинхронный ввод-вывод, pipelining и multiplexing

Рассмотрим пример: копирование файла с одного диска на другой.

Тривиальная реализация будет такой:

```
for (;;) {
    int r = read(fd_src, buf, sizeof(buf));
    write(fd_dst, buf, sizeof(buf));
}
```

Эффективна ли она?

Синхронный и асинхронный ввод-вывод

Диск, если начал операцию, не прерывает её до тех пор, пока она не завершится.
API для работы с файлами сохранили это же свойство – они не отдают управление, пока не завершатся.

```
for (;;) {
   int r = read(fd_src, buf, sizeof(buf));
   write(fd_dst, buf, sizeof(buf));
}
```

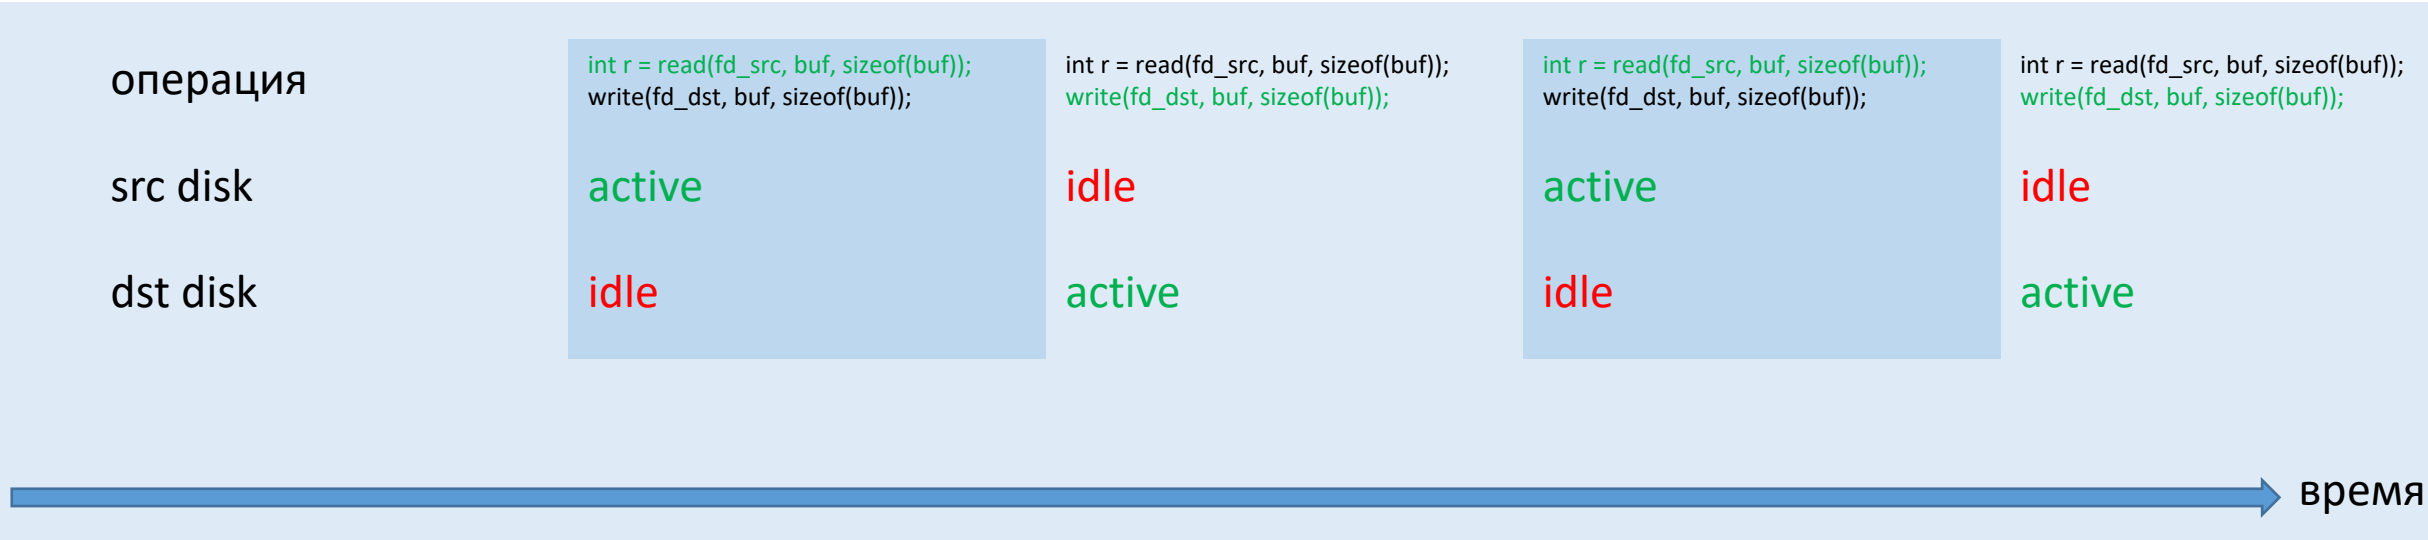

Синхронный и асинхронный ввод-вывод

Диск, если начал операцию, не прерывает её до тех пор, пока она не завершится.
API для работы с файлами сохранили это же свойство – они не отдают управление, пока не завершатся.

```
for (;;) {
   int r = read(fd_src, buf, sizeof(buf));
   write(fd_dst, buf, sizeof(buf));
}
```

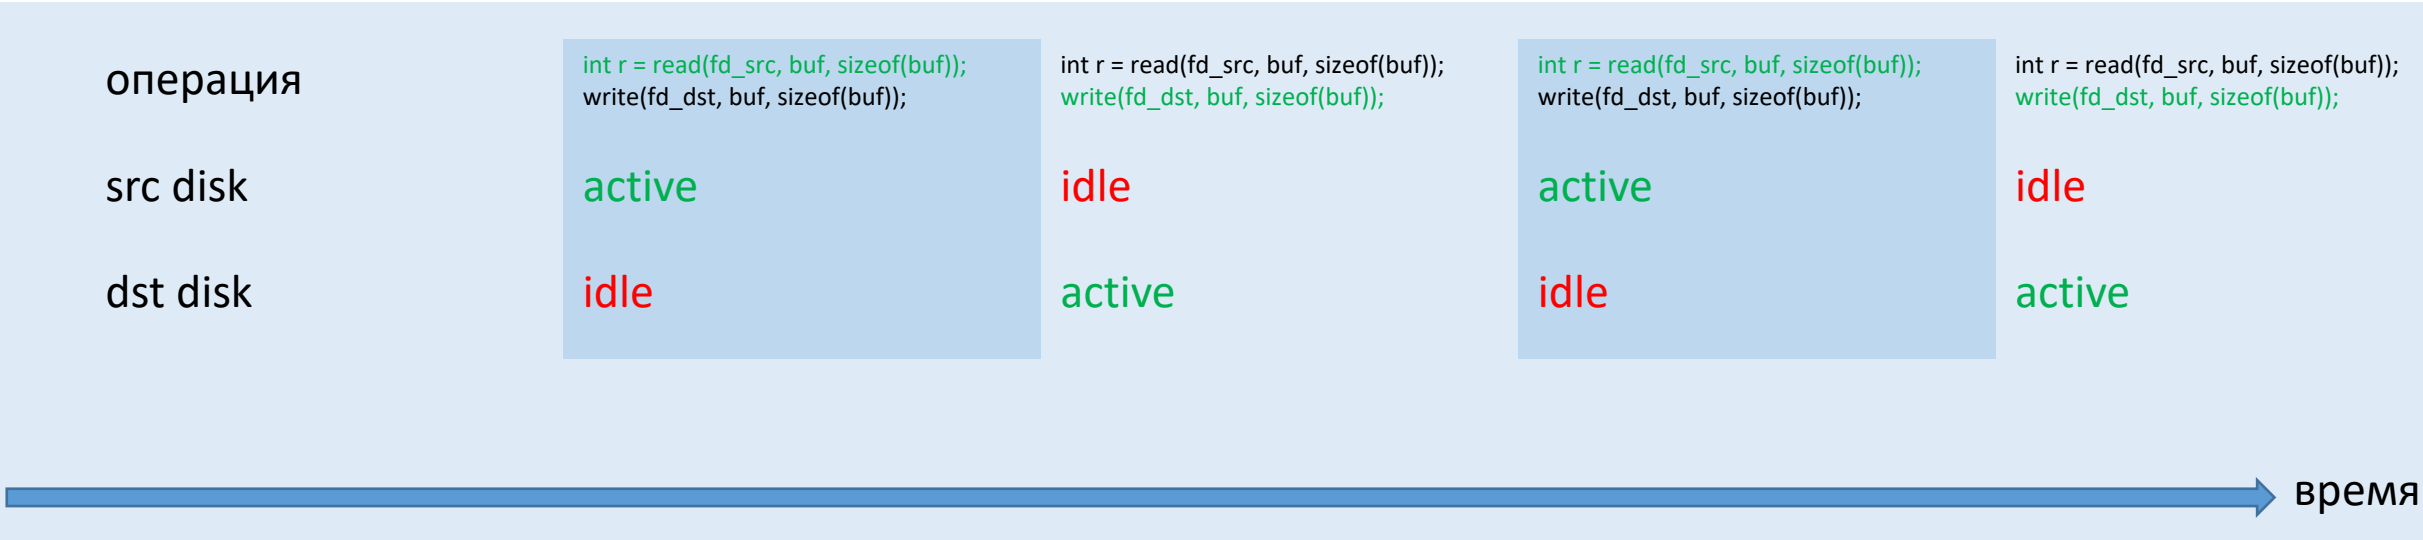

Решение: запросы на запись надо отправлять асинхронно и тут же переходить к чтению следующего блока.

Pipelining и multiplexing

Также надо учитывать время, которое требуется для того, чтобы отослать команду на чтение или запись. Оно было пренебрежимо мало для HDD, но оно велико для сетей и для SSD и NVMe.

```
for (;;) {
    int r = read(fd_src, buf, sizeof(buf));
    write(fd_dst, buf, sizeof(buf));
}
```

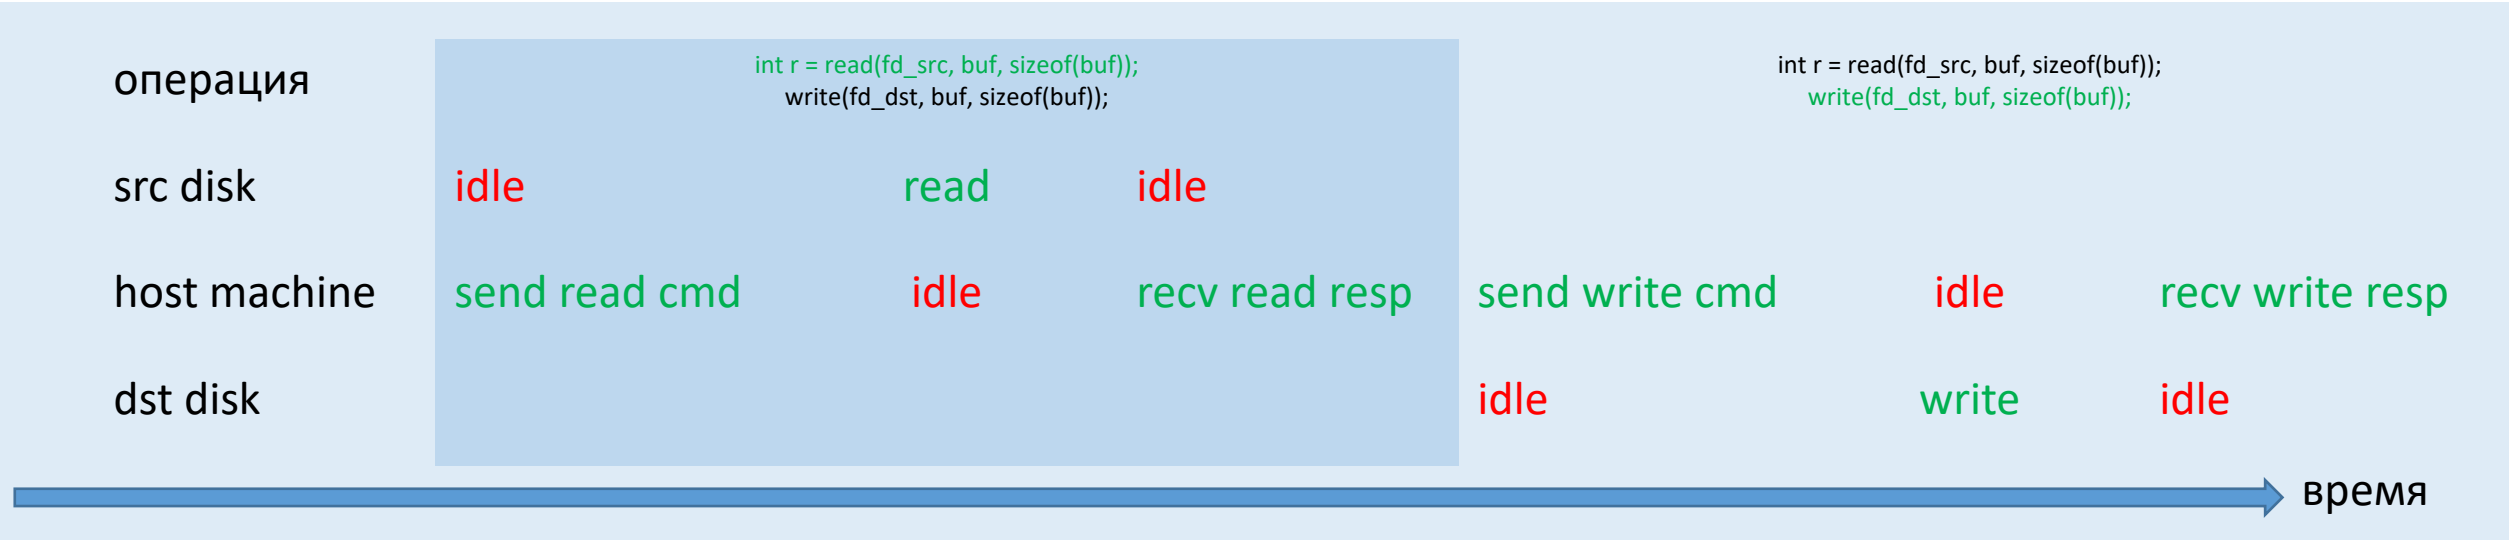

Pipelining и multiplexing

Также надо учитывать время, которое требуется для того, чтобы отослать команду на чтение или запись. Оно было пренебрежимо мало для HDD, но оно велико для сетей и для SSD и NVMe.

```
for (;;) {
    int r = read(fd_src, buf, sizeof(buf));
    write(fd_dst, buf, sizeof(buf));
}
```

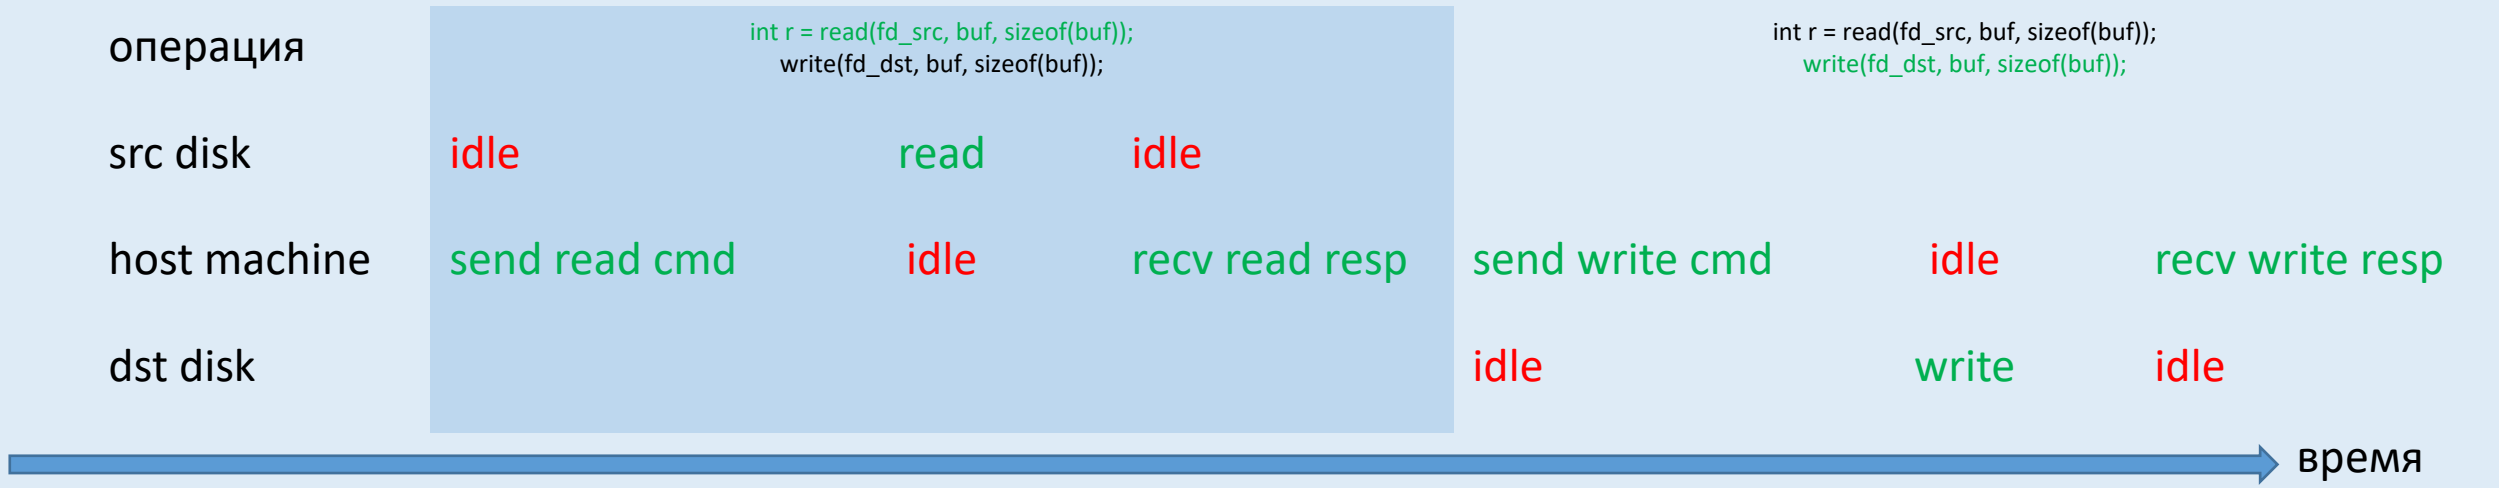

Решение: запросы на чтение надо отправлять в таком количестве, чтобы у диска всегда была непустая очередь команд. Первая команда всё равно увидит задержку на отправку запроса и получение ответа, но для последующих этой задержки не будет.

Pipelining и head-of-line blocking

Предположим, что мы послали много запросов к диску (или к серверу). В каком порядке будут отсылаться ответы?

Есть два возможных варианта:

- в порядке получения запросов,
- в порядке завершения.

Первый вариант (pipelining) зачастую можно реализовать для протоколов, где изначально не позаботились о мультиплексировании.

Второй вариант требует поддержки в протоколе: у запросов должны быть уникальные номера.

Pipelining имеет существенный недостаток: если серверу были отправлены запросы R_1, R_2, …, то R_2 и последующие должны ждать, пока закончится R_1. Если он окажется очень медленным, то все следующие за ним проведут много времени в очереди, даже если бы могли исполниться быстро. Такое явление называется head-of-line blocking.

Pipelining и head-of-line blocking

Предположим, что мы послали много запросов к диску (или к серверу). В каком порядке будут отсылаться ответы?

Есть два возможных варианта:
- в порядке получения запросов,
- в порядке завершения.

Первый вариант (pipelining) зачастую можно реализовать для протоколов, где изначально не позаботились о мультиплексировании.

Второй вариант требует поддержки в протоколе: у запросов должны быть уникальные номера.

Pipelining имеет существенный недостаток: если серверу были отправлены запросы R_1, R_2, …, то R_2 и последующие должны ждать, пока закончится R_1. Если он окажется очень медленным, то все следующие за ним проведут много времени в очереди, даже если бы могли исполниться быстро. Такое явление называется head-of-line blocking.

Дополнительное чтение:
- Google, “The QUIC Transport Protocol”, https://research.google.com/pubs/archive/46403.pdf
- Daniel Bernstein, “HTTP 2 explained”, https://legacy.gitbook.com/book/bagder/http2-explained/details