Основы построения файловых систем

Сегодня мы рассмотрим устройство ФС ext2

Немного терминологии:

- Block – несколько подряд идущих секторов; в ext2 является минимальной единицей места, выделяемого под файл.
- Inode (index node) – структура, описывающая, как расположен на диске один файл.

Index nodes (src/linux/fs/ext2/ext2.h)

В ext2 информация о свойствах файла и его расположении на диске локализована в самом файле:

```
struct ext2_inode {
    __le16  i_mode;     /* File mode */
    __le16  i_uid;      /* Low 16 bits of Owner Uid */
    __le32  i_size;     /* Size in bytes */
    __le32  i_atime;    /* Access time */
    __le32  i_ctime;    /* Creation time */
    __le32  i_mtime;    /* Modification time */
    __le32  i_dtime;    /* Deletion Time */
    __le16  i_gid;      /* Low 16 bits of Group Id */
    __le16  i_links_count;  /* Links count */
```

Index nodes (src/linux/fs/ext2/ext2.h)

В ext2 информация о свойствах файла и его расположении на диске локализована в самом файле:

```
        __le32  i_blocks;   /* Blocks count */
        __le32  i_flags;    /* File flags */
        __le32 osd1;
        __le32  i_block[EXT2_N_BLOCKS];/* Pointers to blocks */
        __le32  i_generation;   /* File version (for NFS) */
        __le32  i_file_acl; /* File ACL */
        __le32  i_dir_acl;  /* Directory ACL */
        __le32  i_faddr;    /* Fragment address */
        __le8 osd2[12];
};
```

Index nodes (src/linux/fs/ext2/ext2.h)

В ext2_inode->i_block[] хранится список блоков, которые составляют файл.

Index nodes (src/linux/fs/ext2/ext2.h)

В ext2_inode->i_block[] хранится список блоков, которые составляют файл. Но в этом массиве 15 элементов.
Как быть с файлами, которые длиннее 15 блоков?

Index nodes (src/linux/fs/ext2/ext2.h)

В ext2_inode->i_block[] хранится список блоков, которые составляют файл. Но в этом массиве 15 элементов.
Как быть с файлами, которые длиннее 15 блоков?

Последние три элемента в i_block[] косвенные, т.е. указывают на блоки, которые сами являются списками блоков.

Index nodes (src/linux/fs/ext2/ext2.h)

В ext2_inode->i_block[] хранится список блоков, которые составляют файл. Но в этом массиве 15 элементов.
Как быть с файлами, которые длиннее 15 блоков?

Последние три элемента в i_block[] косвенные, т.е. указывают на блоки, которые сами являются списками блоков.
Они имеют уровни косвенности 1, 2 и 3, соответственно.

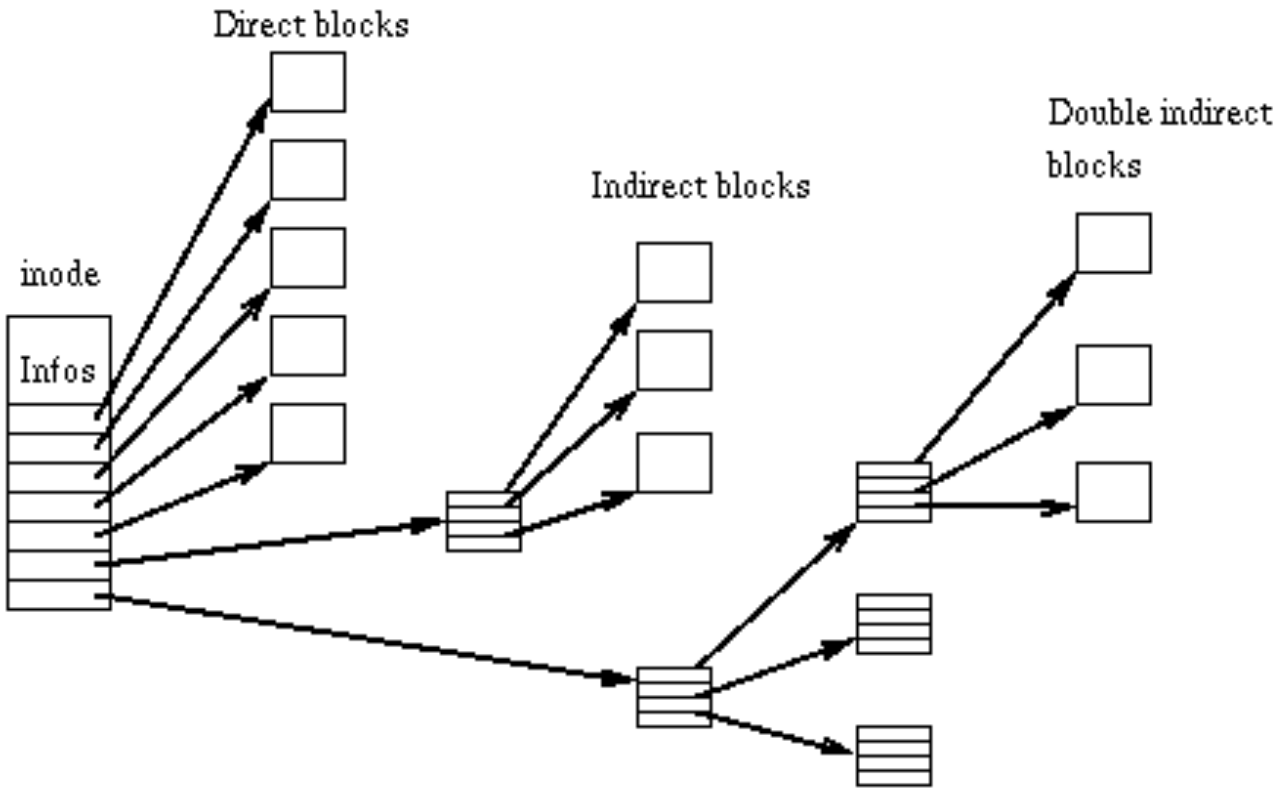

Каталоги в ext2

Каталог хранится в файле специального типа (у которого младший байт i_mode равен EXT2_FT_DIR).
Содержимое файла представляет собой последовательность записей переменной длины:

- В заголовке записи стоит

```
struct ext2_dir_entry_2 {
    __le32  inode;          /* Inode number */
    __le16  rec_len;        /* Directory entry length */
    __u8    name_len;       /* Name length */
    __u8    file_type;
    char    name[];         /* File name, up to EXT2_NAME_LEN */
};
```

- После struct ext2_dir_entry_2 следует имя файла.

Каталоги в ext2

Каталог хранится в файле специального типа (у которого младший байт i_mode равен EXT2_FT_DIR).
Содержимое файла представляет собой последовательность записей переменной длины:

- В заголовке записи стоит

```
struct ext2_dir_entry_2 {
    __le32  inode;          /* Inode number */
    __le16  rec_len;        /* Directory entry length */
    __u8    name_len;       /* Name length */
    __u8    file_type;
    char    name[];         /* File name, up to EXT2_NAME_LEN */
};
```

- После struct ext2_dir_entry_2 следует имя файла.

Примечание: запись об элементе каталога никогда не пересекает границы блока; rec_len у последней записи подбирается так, чтобы она заканчивалась точно на границе.
Ещё примечание: если поле inode равно нулю, то считается, что список в текущем блоке закончился.

Каталоги в ext2

Каталог хранится в файле специального типа (у которого младший байт i_mode равен EXT2_FT_DIR).
Содержимое файла представляет собой последовательность записей переменной длины:

- В заголовке записи стоит

```
struct ext2_dir_entry_2 {
    __le32  inode;          /* Inode number */
    __le16  rec_len;        /* Directory entry length */
    __u8    name_len;       /* Name length */
    __u8    file_type;
    char    name[];         /* File name, up to EXT2_NAME_LEN */
};
```

- После struct ext2_dir_entry_2 следует имя файла.

Примечание: запись об элементе каталога никогда не пересекает границы блока; rec_len у последней записи подбирается так, чтобы она заканчивалась точно на границе.
Ещё примечание: если поле inode равно нулю, то считается, что список в текущем блоке закончился.

Как быть с удалением элементов каталога?

Каталоги в ext3 (hash indexed dirs)

Для больших каталогов используется следующее представление*:

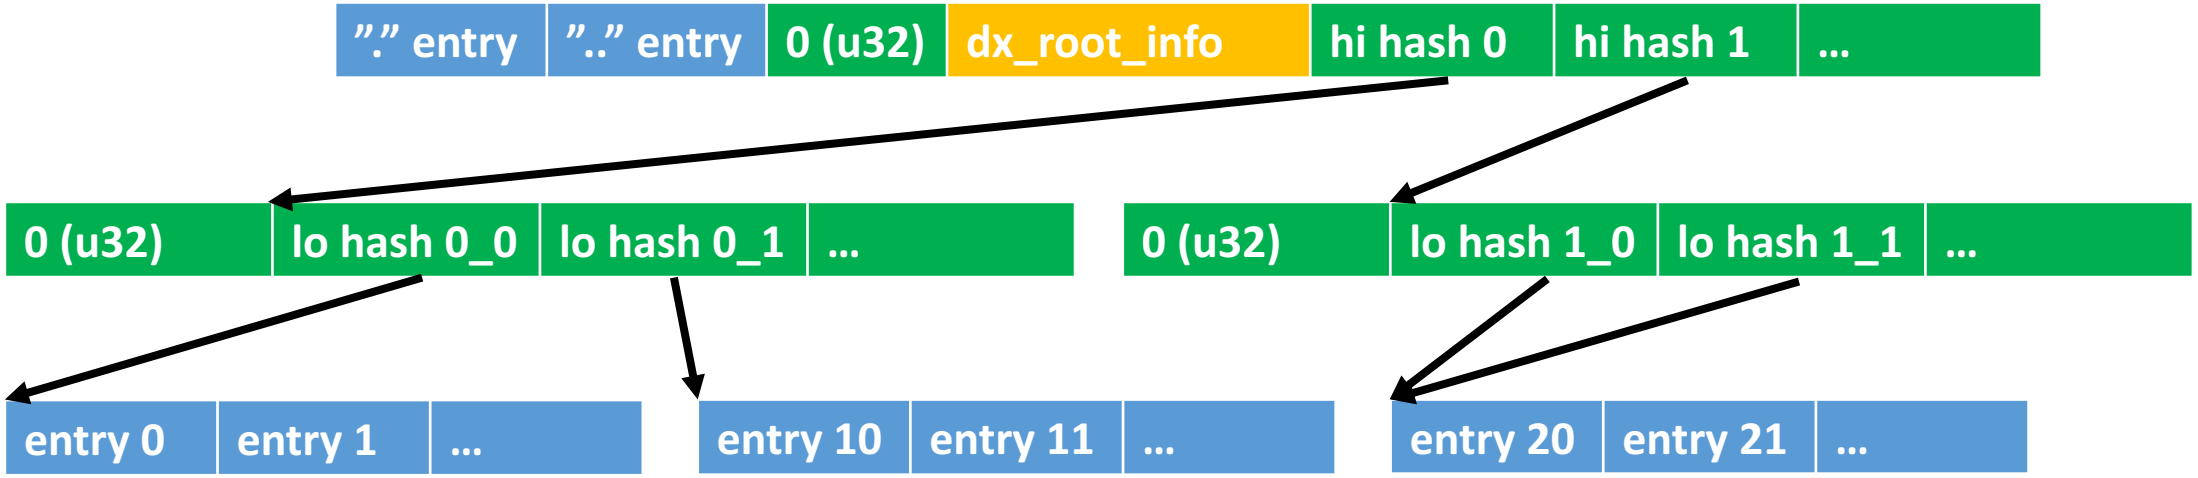

** Каждый узел изображённого дерева занимает один блок на диске.*

Каталоги в ext3 (hash indexed dirs)

Для больших каталогов используется следующее представление*:

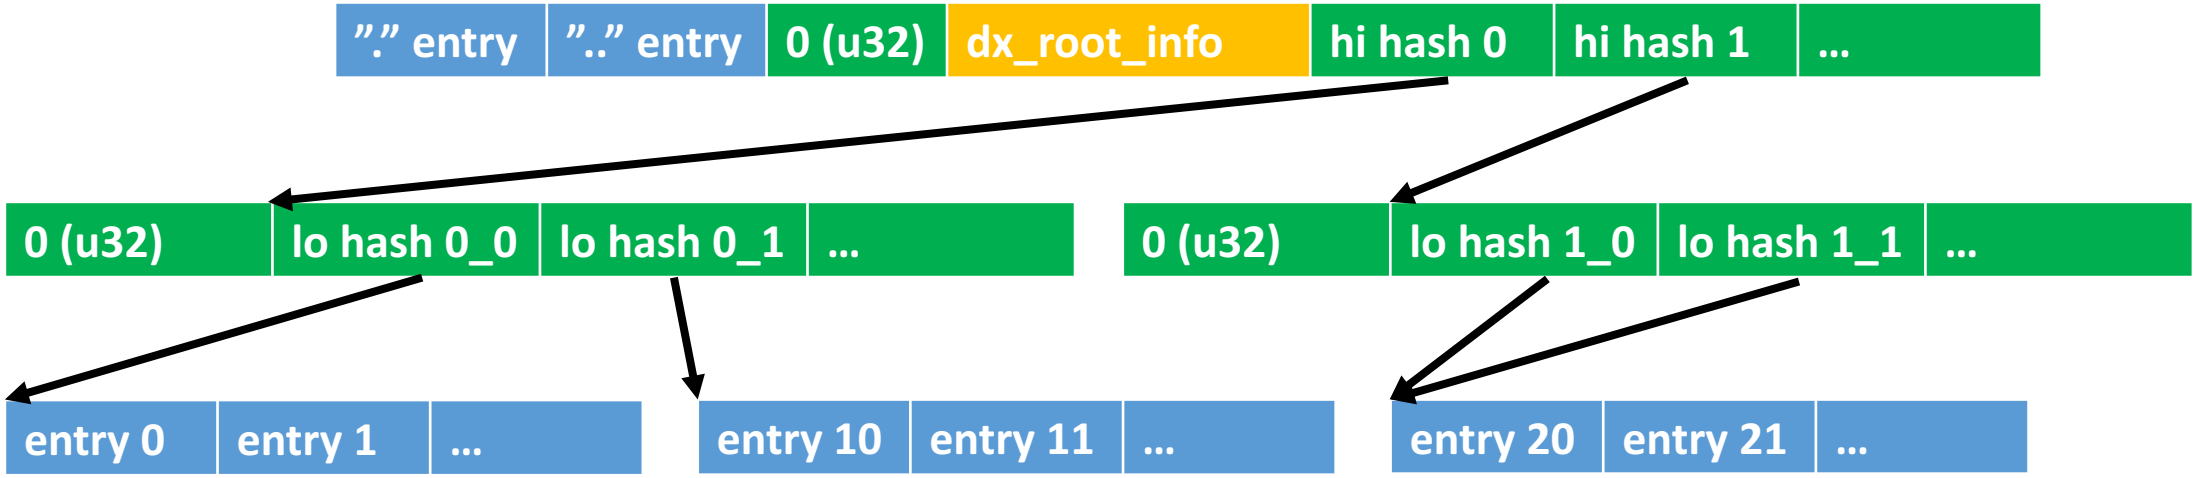

- Если много имён имеют совпадающий хеш и их список не умещается в один блок, то в карте “хеш → номер блока” ставится флаг «список продолжается в следующем блоке».
- Разные хеши могут ссылаться на один блок.

** Каждый узел изображённого дерева занимает один блок на диске.*

Каталоги в ext3 (hash indexed dirs)

Для больших каталогов используется следующее представление*:

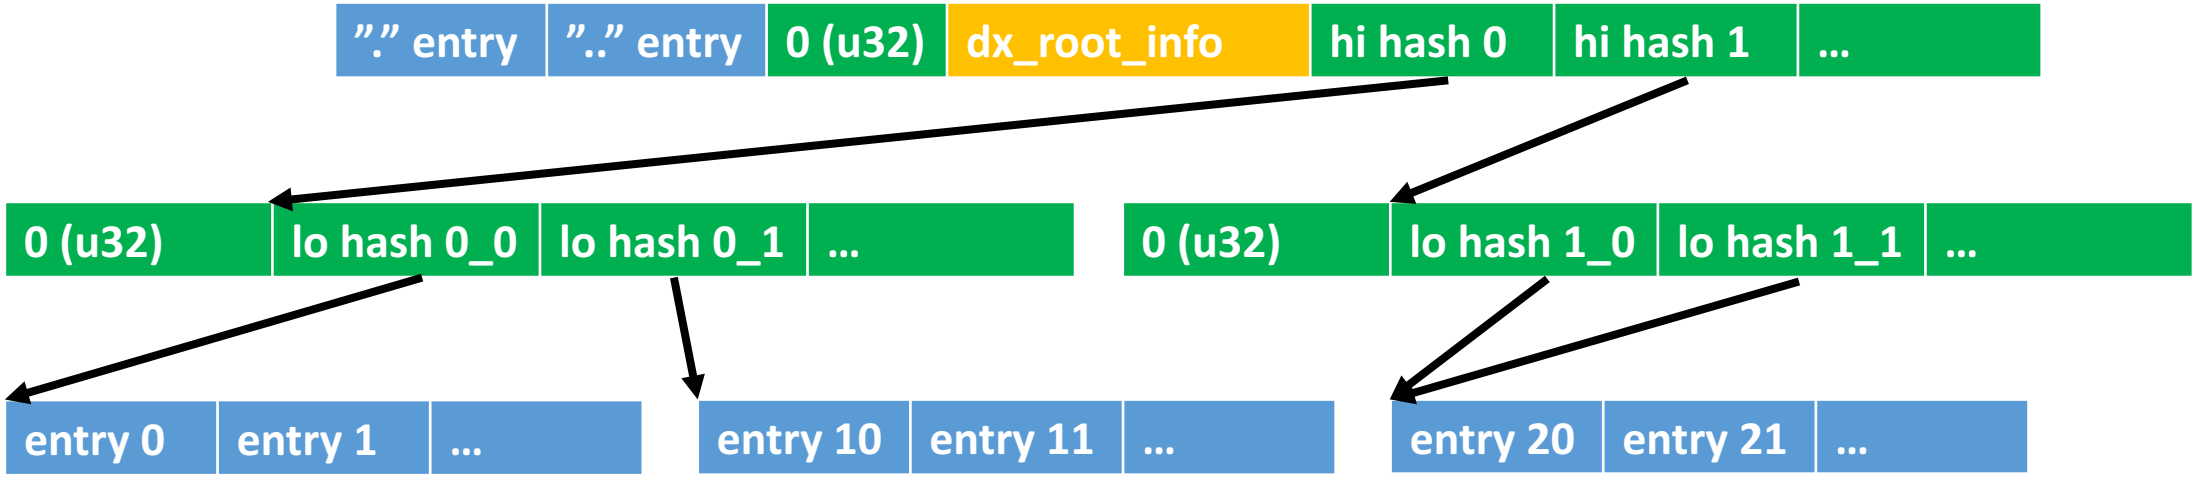

- Если много имён имеют совпадающий хеш и их список не умещается в один блок, то в карте “хеш → номер блока” ставится флаг «список продолжается в следующем блоке».
- Разные хеши могут ссылаться на один блок.

Изображённые выше блоки на диске располагаются подряд (и составляют один файл).

** Каждый узел изображённого дерева занимает один блок на диске.*

Каталоги в ext3 (hash indexed dirs)

Для больших каталогов используется следующее представление*:

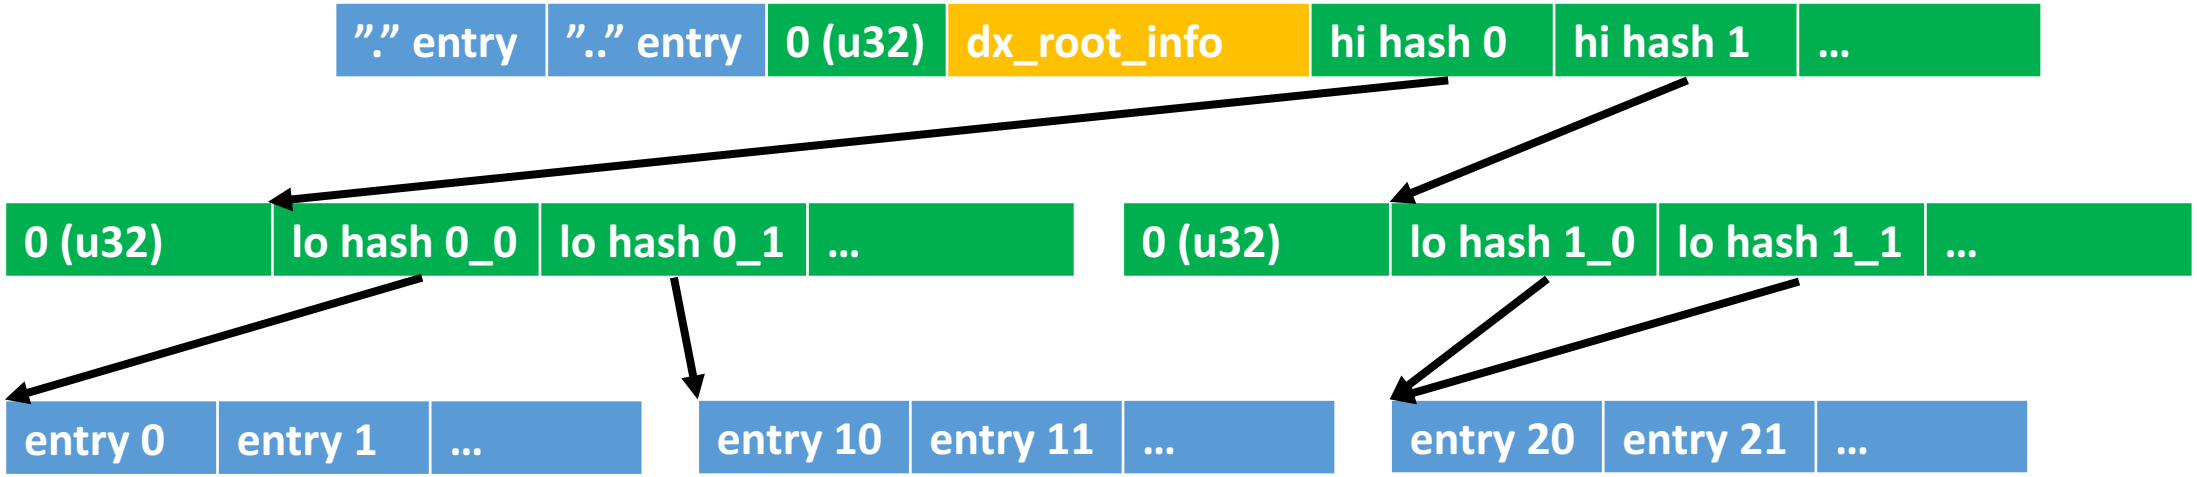

- Если много имён имеют совпадающий хеш и их список не умещается в один блок, то в карте "хеш → номер блока" ставится флаг «список продолжается в следующем блоке».
- Разные хеши могут ссылаться на один блок.

Изображённые выше блоки на диске располагаются подряд (и составляют один файл).

Нулевые записи в блоках нижнего уровня и нулевое 4-байтовое значение в корневом блоке поставлены затем, чтобы алгоритм линейного поиска из ext2 увидел правильный список элементов (вспоминаем, что элемент с нулевым полем inode – это признак «в этом блоке больше нет записей»).

** Каждый узел изображённого дерева занимает один блок на диске.*

Слежение за свободным и занятым местом

ФС разделена на группы блоков; учёт занятого места ведётся в пределах группы. Информация об одной группе умещается в памяти.

```
struct ext2_group_desc
{
    __le32  bg_block_bitmap;        /* Blocks bitmap block */
    __le32  bg_inode_bitmap;        /* Inodes bitmap block */
    __le32  bg_inode_table;     /* Inodes table block */
    __le16  bg_free_blocks_count;   /* Free blocks count */
    __le16  bg_free_inodes_count;   /* Free inodes count */
    __le16  bg_used_dirs_count; /* Directories count */
    __le16  bg_pad;
    __le32  bg_reserved[3];
};
```

- Число блоков и инод в каждой группе одинаковое и задаётся при создании ФС
- Имеющиеся в одной группе иноды расположены непрерывным блоком
- Блоки, на которые ссылается инода, ФС старается выделять из группы, которой та принадлежит.

Устройство ext2 в целом

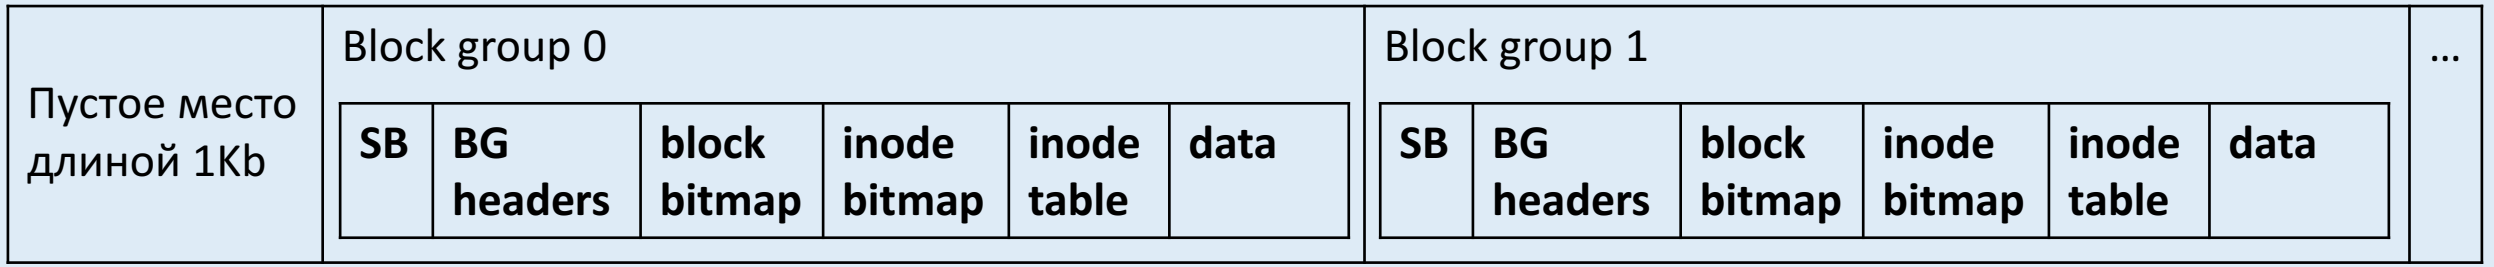

Суперблок ext2 (src/linux/fs/ext2/ext2.h, struct ext2_super_block)

```
struct ext2_super_block {
    __le32  s_inodes_count;      /* Inodes count */
    __le32  s_blocks_count;      /* Blocks count */
    __le32  s_r_blocks_count;    /* Reserved blocks count */
    __le32  s_free_blocks_count;     /* Free blocks count */
    __le32  s_free_inodes_count;     /* Free inodes count */
    __le32  s_first_data_block; /* First Data Block */
    __le32  s_log_block_size;    /* Block size */
    __le32  s_log_frag_size;     /* Fragment size */
    __le32  s_blocks_per_group; /* # Blocks per group */
    __le32  s_frags_per_group;  /* # Fragments per group */
    __le32  s_inodes_per_group; /* # Inodes per group */
```

Суперблок ext2 (src/linux/fs/ext2/ext2.h, struct ext2_super_block)

```
__le32  s_mtime;         /* Mount time */
__le32  s_wtime;         /* Write time */
__le16  s_mnt_count;      /* Mount count */
__le16  s_max_mnt_count;  /* Maximal mount count */
__le16  s_magic;         /* Magic signature */
__le16  s_state;         /* File system state */
__le16  s_errors;        /* Behaviour when detecting errors */
__le16  s_minor_rev_level;  /* minor revision level */
__le32  s_lastcheck;      /* time of last check */
__le32  s_checkinterval;  /* max. time between checks */
__le32  s_creator_os;     /* OS */
__le32  s_rev_level;      /* Revision level */
```

Суперблок ext2 (src/linux/fs/ext2/ext2.h, struct ext2_super_block)

```
__le32  s_feature_compat;   /* compatible feature set */
__le32  s_feature_incompat;     /* incompatible feature set */
__le32  s_feature_ro_compat;    /* readonly-compatible feature set */
__u8    s_uuid[16];     /* 128-bit uuid for volume */
char    s_volume_name[16];  /* volume name */
char    s_last_mounted[64];     /* directory where last mounted */
__le32  s_algorithm_usage_bitmap; /* For compression */
/*
 * Performance hints.  Directory preallocation should only
 * happen if the EXT2_COMPAT_PREALLOC flag is on.
 */
__u8    s_prealloc_blocks;  /* Nr of blocks to try to preallocate*/
__u8    s_prealloc_dir_blocks;  /* Nr to preallocate for dirs */
__u16   s_padding1;
```

Compat, ro-compat, incompat features

Compat features: старые реализации ext2 могут и читать, и писать на такую файловую систему.

RO-compat features: старые реализации могут корректно читать такую ФС, но писать в неё уже нет.

Incompat features: старые реализации не могут смонтировать такую ФС.

Compat, ro-compat, incompat features

Compat features: старые реализации ext2 могут и читать, и писать на такую файловую систему.

RO-compat features: старые реализации могут корректно читать такую ФС, но писать в неё уже нет.

Incompat features: старые реализации не могут смонтировать такую ФС.

Compat-discard features (QCOW2): старые реализации могут и читать, и писать, но должны обнулить указатели на структуры, которые они не поддерживают.

Пример: CBT map (Changed Block Tracking map).

Compat, ro-compat, incompat features

Compat features: старые реализации ext2 могут и читать, и писать на такую файловую систему.

- EXT4_FEATURE_COMPAT_DIR_PREALLOC
- EXT4_FEATURE_COMPAT_HAS_JOURNAL
- EXT4_FEATURE_COMPAT_EXT_ATTR
- EXT4_FEATURE_COMPAT_RESIZE_INODE
- EXT4_FEATURE_COMPAT_DIR_INDEX

Compat, ro-compat, incompat features

Compat features: старые реализации ext2 могут и читать, и писать на такую файловую систему.

- EXT4_FEATURE_COMPAT_DIR_PREALLOC
- EXT4_FEATURE_COMPAT_HAS_JOURNAL
- EXT4_FEATURE_COMPAT_EXT_ATTR
- EXT4_FEATURE_COMPAT_RESIZE_INODE
- EXT4_FEATURE_COMPAT_DIR_INDEX

Ro-compat features: старые реализации могут корректно читать такую ФС, но писать в неё уже нет.

- EXT4_FEATURE_RO_COMPAT_SPARSE_SUPER
- EXT4_FEATURE_RO_COMPAT_HUGE_FILE
- EXT4_FEATURE_RO_COMPAT_QUOTA

Compat, ro-compat, incompat features

Compat features: старые реализации ext2 могут и читать, и писать на такую файловую систему.

- EXT4_FEATURE_COMPAT_DIR_PREALLOC
- EXT4_FEATURE_COMPAT_HAS_JOURNAL
- EXT4_FEATURE_COMPAT_EXT_ATTR
- EXT4_FEATURE_COMPAT_RESIZE_INODE
- EXT4_FEATURE_COMPAT_DIR_INDEX

Ro-compat features: старые реализации могут корректно читать такую ФС, но писать в неё уже нет.

- EXT4_FEATURE_RO_COMPAT_SPARSE_SUPER
- EXT4_FEATURE_RO_COMPAT_HUGE_FILE
- EXT4_FEATURE_RO_COMPAT_QUOTA

Incompat features: старые реализации не могут смонтировать такую ФС.

- EXT4_FEATURE_INCOMPAT_COMPRESSION
- EXT4_FEATURE_INCOMPAT_JOURNAL_DEV
- EXT4_FEATURE_INCOMPAT_EXTENTS
- EXT4_FEATURE_INCOMPAT_INLINE_DATA
- EXT4_FEATURE_INCOMPAT_ENCRYPT

Пример (почти) compat feature: 32-битные UID и GID владельца

Напоминание: хвост struct ext2_inode выглядит так:

```
    __le32  i_block[EXT2_N_BLOCKS];/* Pointers to blocks */
    __le32  i_generation;   /* File version (for NFS) */
    __le32  i_file_acl; /* File ACL */
    __le32  i_dir_acl;  /* Directory ACL */
    __le32  i_faddr;    /* Fragment address */
    __le8 osd2[12];
};
```

Операционные системы, которые не используют поле osd2, должны сохранять его без изменений.

Пример (почти) compat feature: 32-битные UID и GID владельца

Для linux хвост struct ext2_inode выглядит так:

```
    __le32  i_block[EXT2_N_BLOCKS];/* Pointers to blocks */
    __le32  i_generation;   /* File version (for NFS) */
    __le32  i_file_acl; /* File ACL */
    __le32  i_dir_acl;  /* Directory ACL */
    __le32  i_faddr;    /* Fragment address */
    union {
        struct {
            __u8    l_i_frag;   /* Fragment number */
            __u8    l_i_fsize;  /* Fragment size */
            __u16   i_pad1;
            __le16  l_i_uid_high;   /* these 2 fields    */
            __le16  l_i_gid_high;   /* were reserved2[0] */
            __u32   l_i_reserved2;
        } linux2;
    } osd2;                 /* OS dependent 2 */
};
```

Дополнительное чтение

- http://www.nongnu.org/ext2-doc
- https://ext4.wiki.kernel.org/index.php/Ext4_Disk_Layout
- http://wiki.osdev.org/Ext2

- https://lwn.net/Articles/322823/

Домашнее задание

1. Почему htree directories (EXT4_FEATURE_COMPAT_DIR_INDEX) – это compat feature?
2. Разобраться с mkfs.ext2, создать образ ext2, и написать программу, которая
   - Перечислит элементы в любом каталоге по номеру его inode,
   - (*) Перечислит элементы в любом каталоге, заданном путём,
   - Прочтёт файл, заданный номером его inode,
   - (*) Прочтёт файл, заданный путём.
3. (***) Реализовать модуль для FUSE, который примонтирует образ ext2 в режиме только для чтения.